

Projektarbeit Data Management und Archivierung im Umfeld der Forschung

WS 25/26

Gruppe 3

**Mapping-Konzept und Integration in CDISC (SDTM/ODM/ADaM) mit anschließender ML-basierter
Vorhersage der Aufenthaltsdauer**

Bearbeitungszeit	4 Wochen (Teamarbeit, 4 – 5 Personen)
Datenbasis	Synthea Demo-Daten (CSV-Export)
Zielmodell / Standard	CDISC SDTM / ODM / ADaM (flexibel)
ML-Aufgabe	Aufenthaltsdauer
Abgabeformat	GitHub-Repo oder Google Colab + Slides + 1-seitige Executive Summary
Abgabefrist	11. Feb. 2026, bis 17h, per Mail an: gaetankamdje.wabo@master-bids.de

Zielsetzung

Entwerft ein CDISC-orientiertes Mapping-Konzept: Ableitung von SDTM-Domains aus Synthea-CSV, Export/Metadaten via ODM-XML und Ableitung von ADaM-Analysedatensätzen. Baut darauf ein ML-Modell zur Vorhersage der Aufenthaltsdauer.

Kern-Fragestellungen

- Wie lassen sich Synthea-CSV (Versorgungsdaten) in ein CDISC-konformes Tabulationspaket (SDTM) ueberfuehren, inkl. Visits/Timing?
- Welche SDTM-Domains sind fuer die Demo sinnvoll (Minimum: DM, VS, LB, MH, CM/EX, PR) und wie werden sie aus Synthea abgeleitet?
- Wie werden Metadaten und Datenpaket austauschbar gemacht (ODM) und wie leitet ihr Analyse-Datensätze nach ADaM (ADSL/BDS) ab?
- Wie koennen Aufenthaltsdauer Labels plausibel aus SDTM/ADaM abgebildet werden (Timing, Missing Stop, Mehrfachvisits)?
- Wie kann die Krankenhaus Aufenthaltsdauer basiert auf SDTM/ADAM-integrierten Daten ML-basiert vorhergesagt werden?

Demo-Datenbasis: Synthea CSV (Cohort-Simulation)

Alle Gruppen arbeiten auf denselben synthetischen Synthea-Demo-Daten (CSV-Export). Die Daten sind nicht echt (synthetisch), bilden aber realistische Versorgungsabläufe ab und enthalten standardisierte Codes (SNOMED-CT, RxNorm, LOINC, CVX).

Übersicht zentrale Tabellen (empfohlen als Minimum fuer das Mapping):

- Synthea Datenbeschreibung: <https://github.com/synthetichealth/synthea/wiki/CSV-File-Data-Dictionary>
- Synthea Sample CSV Zip: https://synthetichealth.github.io/synthea-sample-data/downloads/latest/synthea_sample_data_csv_latest.zip

CSV-Datei	Inhalt / wichtigste Schluesel
patients.csv	Demografie, BirthDate, DeathDate, Gender, Race/Ethnicity, Address, Income; PK: Id
encounters.csv	Versorgungsfall/Visit: Start/Stop, EncounterClass, Organization, Provider, Payer; PK: Id; FK: Patient
conditions.csv	Diagnosen (meist SNOMED-CT): Start/Stop, Patient, Encounter, Code, System, Description
observations.csv	Messwerte/Labore (meist LOINC): Date, Patient, Encounter, Code, Value, Units, Type
medications.csv	Medikation (RxNorm): Start/Stop, Patient, Encounter, Code, Base_Cost, Dispenses, ReasonCode
procedures.csv	Prozeduren (SNOMED-CT): Start/Stop, Patient, Encounter, Code, Base_Cost, ReasonCode
immunizations.csv	Impfungen (CVX): Date, Patient, Encounter, Code, Cost
allergies.csv	Allergien/Intoleranzen: Start/Stop, Patient, Encounter, Code, System, Severity
careplans.csv	Behandlungsplaene/Goals (SNOMED-CT): Start/Stop, Patient, Encounter, Code, ReasonCode
devices.csv	Devices (SNOMED-CT): Start/Stop, Patient, Encounter, UDI
imaging_studies.csv	Bildgebungs-Metadaten (DICOM UID + SNOMED BodySite): Date, Patient, Encounter, Modality
organizations.csv	Einrichtungen: Name, Address, Utilization, Revenue; PK: Id
providers.csv	Behandelnde: Name, Specialty, Organization; PK: Id
payers.csv	Kostentraeger: Name, Ownership, Revenue; PK: Id
payer_transitions.csv	Versicherungswechsel: Patient, Member ID, Start_Year/End_Year, Payer
claims.csv / claims_transactions.csv	Abrechnung (optional fuer dieses Projekt); Verknuepfungen ueber Patient/Provider/Appointment

Join-Logik (praktisch wichtig): Patient-UUID verbindet fast alle klinischen Tabellen; Encounter-UUID verbindet Ereignisse innerhalb eines Visits; Organization/Provider/Payer ergaenzen Kontext.

Gemeinsame Mindestanforderungen

Hinweis: alle Beispiele bei den Unterpunkten sind nur Vorschläge, Ihr könnt immer noch eigene Lösungswege erarbeiten!!!

1) Data-Warehouse-Konzept & technische Basis

- Zielarchitektur (Skizze): Raw Zone -> Staging -> Model (CDISC) -> Analytics/ML
- Technische Entscheidung dokumentieren: Datenbank (z.B. SQLite) + ETL (Python/SQL) + Containerisierung (Docker)
- Reproduzierbarkeit: 'one-command run' (Makefile oder bash), feste Paketversionen, Seed fuer ML

2) Mapping-Konzept & Integration

- Mapping der Synthea-CSV in das Zielmodell (OMOP CDM) inkl. Mapping-Tabellen/Regeln
- Mindestens: Patienten, Encounters/Visits, Diagnosen, Labor/Observations, Medikation, Prozeduren
- Data Quality Checks: Vollstaendigkeit, Referential Integrity, Plausibilitaet (Datum, Wertebereiche), Duplikate

3) Machine-Learning-Konzept

- Vorhersageziel: Mortalität (praezise Definition + Label-Generierung aus Synthea)
- Feature Engineering: Demografie, Komorbiditaet/Diagnosen, Vorbefunde, Medikation, Labor, Voraufenthalte
- Modelle: Baseline (LogReg/Linear), Tree-based (RandomForest/XGBoost oder LightGBM), ggf. Calibration
- Evaluation: Train/Val/Test Split (zeitlich oder patientenbasiert), passende Metriken, Bias/Leakage Checks

4) Archivierungs- und Reproduktionskonzept

- Datenversionierung (Snapshots/Checksums), Code-Versionierung (Git), Artefakte (Model, Features)
- Provenance: Pipeline-Run-IDs, Konfigurationsdateien, Logging, Data Dictionary
- Langfristige Ablage: strukturierter Ordner (raw/staging/model/outputs/docs), Exportformate (CSV/Parquet, SQL dumps)

5) Abgaben (Ende Woche 4)

- GitHub-Repository oder Google-Colab-Notebook(s) inkl. Anleitung zum Start
- Präsentation (ca. 12–15 Minuten) + Live-Demo oder Screenshots
- 1-seitige Executive Summary (Problem, Methode, Ergebnisse, Lessons Learned, Limitations)

ML-Zielvariable: Krankenhaus Aufenthaltsdauer

Hinweis: Alle Beispiele bei den Unterpunkten sind nur Vorschläge, Ihr könnt immer noch eigene Lösungswege erarbeiten!!!

- Ziel: Aufenthaltsdauer (LOS) fuer stationaere Encounters (Regression).
- Index-Fall: inpatient Encounter; LOS = (Stop - Start) in Tagen (float oder integer).
- Filter: Stop vorhanden und Stop >= Start; optional: Winsorize extreme Ausreisser (dokumentieren!).
- Metriken: MAE und RMSE; zusaetzlich R² als Orientierung.
- Split: patientenbasiert; optional: log(LOS) Transformation testen (dokumentieren).

Wochenplan (verbindliche Meilensteine)

Hinweis: Alle Beispiele bei den Unterpunkten sind nur Vorschläge, Ihr könnt immer noch eigene Lösungswege erarbeiten!!!

Woche	Arbeitsschritte (Checklist)	Zwischenergebnisse / Abgabe
Woche 1	• Einarbeitung in CSV Synthea Daten • Einarbeitung in SDTM, ADAM, ODM Daten Model • Repository/Colab anlegen, Rollen verteilen, Definition of Done festlegen • Synthea CSV einlesen, Data Profiling (Missingness, Keys, Zeitfelder, Duplikate) • Zielarchitektur + DWH-Konzept (Raw/Staging/Model) skizzieren; ERD-Entwurf • Outcome-Definition finalisieren (Label-Logik) und Leakage-Risiken prüfen	• Kurzdesign (1–2 Seiten): Architekturdiagramm + ERD Draft • Datenprofiling Notebook + erste Datenqualitätschecks • Festgelegte Outcome-Definition + Cohort-Kriterien
Woche 2	• Datenbank aufsetzen (Docker/PostgreSQL oder ähnlich) • ETL: Raw -> Staging (Typen, Normalisierung, Standard-Datumsformate, Surrogate Keys) • Mapping in Zielmodell implementieren (DDL + Loads) • DQ: referentielle Integrität, Mapping-Rate, Plausibilität (z.B. Stop>=Start)	• Lauffähige DWH-Instanz + erste geladenen Tabellen • Mapping-Dokumentation (Mapping-Tabellen/Regeln, Annahmen) • DQ-Report (kurz, mit Kennzahlen)
Woche 3	• Feature Engineering Pipeline (patient/visit-level Features, Aggregationen, Zeitfenster) • Train/Val/Test Split (patientenbasiert oder zeitlich), Baseline Modell trainieren • Modellvergleich (mind. 2 Modellklassen) + Hyperparameter light tuning • Evaluation + Error Analysis (Calibration, Subgruppenchecks soweit möglich)	• Reproduzierbares Feature-Set (Speichern als Parquet/CSV) • Erste ML-Ergebnisse (Metriken + Plots) • Kurze Analyse: wichtigste Features + typische Fehlerfälle
Woche 4	• Finales Modell + robuste Evaluation (inkl. Ablation/Feature importance) • Archivierungskonzept ausformulieren + Pipeline 'one-command run' • Präsentation bauen (Storyline, Demos, Ergebnisse) • Executive Summary (1 Seite) erstellen	• Finaler GitHub/Colab Stand (tagged release) • Slides (PDF/PPTX) + Demo (Notebook/Screen) • 1-seitige Executive Summary + Archivierungskonzept

Archivierungskonzept

Hinweis: Alle Beispiele bei den Unterpunkten sind nur Vorschläge, Ihr könnt immer noch eigene Lösungswege erarbeiten!!!

- Welche Artefakte müssen archiviert werden? (Rohdaten-Snapshot, bereinigte Daten, Mapping-Regeln, SQL-DDL, Notebooks/Skripte, Modelle, Metriken, Slides)

- Wie wird Reproduzierbarkeit sichergestellt? (Docker/Conda, Requirements, deterministische Seeds, feste Versionen)
- Wie werden Datenqualitaet und Mapping-Aenderungen versioniert? (Mapping-Tabellen mit Versionsnummer, Changelog, Test-Suite)
- Wie werden Ergebnisse nachvollziehbar? (Pipeline-Protokoll, Run-Manifest mit Parameter, Checksums, Data Dictionary)

Erwartete Repo-/Colab-Struktur (empfohlen)

Hinweis: Alle Beispiele bei den Unterpunkten sind nur Vorschläge, Ihr könnt immer noch eigene Lösungswege erarbeiten!!!

Eine klare Struktur erleichtert Review, Reproduzierbarkeit und Bewertung.

- README.md (Setup, Datenimport, Pipeline-Run, Troubleshooting)
- data/raw/ (Synthea CSV - optional per Downloadskript)
- data/staging/ (bereinigt/normalisiert)
- sql/ (DDL + Views) oder model/ (Zielmodell)
- etl/ (Python/SQL ETL Skripte)
- notebooks/ (EDA, Feature Engineering, ML Training, Evaluation)
- outputs/ (Tabellen, Plots, Metriken, Modellartefakte)
- docs/ (Architekturdiagramm, Mapping-Doku, Executive Summary)

Präsentation (Prüfungsleistung)

- Problem & Zielmodell kurz einordnen (warum CDISC?)
- Datenbasis & Kohortendefinition (Synthea, Einschlusskriterien, Zielvariable)
- Data Warehouse Design + ETL/Mappings (Schema, Datenfluss, Mapping-Entscheidungen)
- Data Quality Ergebnisse (z.B. Mapping-Rate, Missingness, Checks)
- ML-Pipeline & Ergebnisse (Modelle, Features, Metriken, Fehleranalyse)
- Archivierung/Reproduzierbarkeit (wie kann jemand anderes es 1:1 nachbauen?)
- Fazit: Lessons Learned + Limitations + naechste Schritte

Nuetzliche Links (Implementierung & Standards)

CDISC – SDTM:

<https://www.cdisc.org/standards/foundational/sdtm>

CDISC – SDTMIG:

<https://www.cdisc.org/standards/foundational/sdtmig>

CDISC – SDTMIG v3.4 Seite:

<https://www.cdisc.org/standards/foundational/sdtmig/sdtmig-v3-4>

CDISC – ODM v1.3:

<https://www.cdisc.org/standards/foundational/odm-xml/odm-v13>

CDISC – ODM-XML v1.3.2:

<https://www.cdisc.org/standards/data-exchange/odm-xml/odm-xml-v1-3-2>

CDISC – ADaMIG v1.3:

<https://www.cdisc.org/standards/foundational/adam/adamig-v1-3>

Synthea Repository (CSV Export / Wiki):

- Synthea Datenbeschreibung: <https://github.com/synthetichealth/synthea/wiki/CSV-File-Data-Dictionary>
- Synthea Sample CSV Zip:
https://synthetichealth.github.io/synthea-sample-data/downloads/latest/synthea_sample_data_csv_latest.zip